



Traitement automatique d'électrogrammes transmis par des dispositifs électroniques cardiaques implantables

Tuteur de stage : **Rémi Dubois**
Encadrante universitaire : **Marie Chavent**

NGUYEN Alexandre
M2 CMI ISI

université
de **BORDEAUX**

Soutenance de stage
Du 20/02/2023 au 20/07/2023

Sommaire :

1. Présentation du Liryc
2. Contexte et problématique
3. Travaux réalisés pendant le stage
4. Conclusion
5. Références

1. Présentation du Liryc

1. Présentation du Liryc

- IHU = Institut Hospitalo-Universitaire
- Situé dans le complexe hospitalier Xavier Arnozan à Pessac
- Créé en 2012 grâce au Programme d'Investissement d'Avenir
- Institut dédié à la recherche sur le cœur, son fonctionnement et les pathologies du rythme cardiaque
- Missions de recherche, d'innovation de soins et de formation
- Affilié à l'Université de Bordeaux, CHU de Bordeaux, Inria ainsi qu'à des partenaires industriels du domaine médical

1. Présentation du Liryc




Plusieurs pôles de recherche à l'IHU Liryc :

- ☐ Pôle modélisation
- ☐ Pôle physiopathologie
- ☐ Pôle clinique
- ☐ **Pôle technologie pour la santé :**
 - Équipe imagerie
 - Équipe science de données multimodales
 - **Équipe traitement du signal** : instrumentation et traitement du signal

2. Contexte et problématique

2. Contexte et problématique

- Dispositifs électroniques cardiaques implantés (pacemakers, défibrillateurs) :
 - 410 000 implantés, 80 000 nouvelles implantations chaque année
 - Surveillent l'activité électrique du cœur et corrigent les anomalies
 - Suivi à distance et continu des patients



2. Contexte et problématique


- Fibrillation auriculaire (FA) : activité électrique anarchique et rapide du muscle des oreillettes => contractions désordonnées et inefficaces
→ ne doit pas être traitée par le dispositif
- Détection à tort de FA par le dispositif :
 - Causée par un bruit sur le signal électrique de la **voie auriculaire**
 - Un rythme rapide est pensé comme conséquence de la FA donc non traité

Objectif du stage : Développer un algorithme, basé sur une stratégie de Machine Learning, capable de détecter automatiquement une FA sur l'EGM du dispositif d'un patient.

→ Discrimination FA d'un autre évènement qui doit être traité

2. Contexte et problématique

- > 10 000 EGM labellisés manuellement par 3 médecins en 2 classes :
 - '1' ou 'AF' : l'EGM présente bien une FA
 - '0' ou 'other' : l'EGM ne présente pas de FA
- Consensus sur 10 172 EGM : **base de données utilisées**
 - 8057 enregistrements de classe 1
 - 2115 enregistrements de classe 0
 - 652 patients



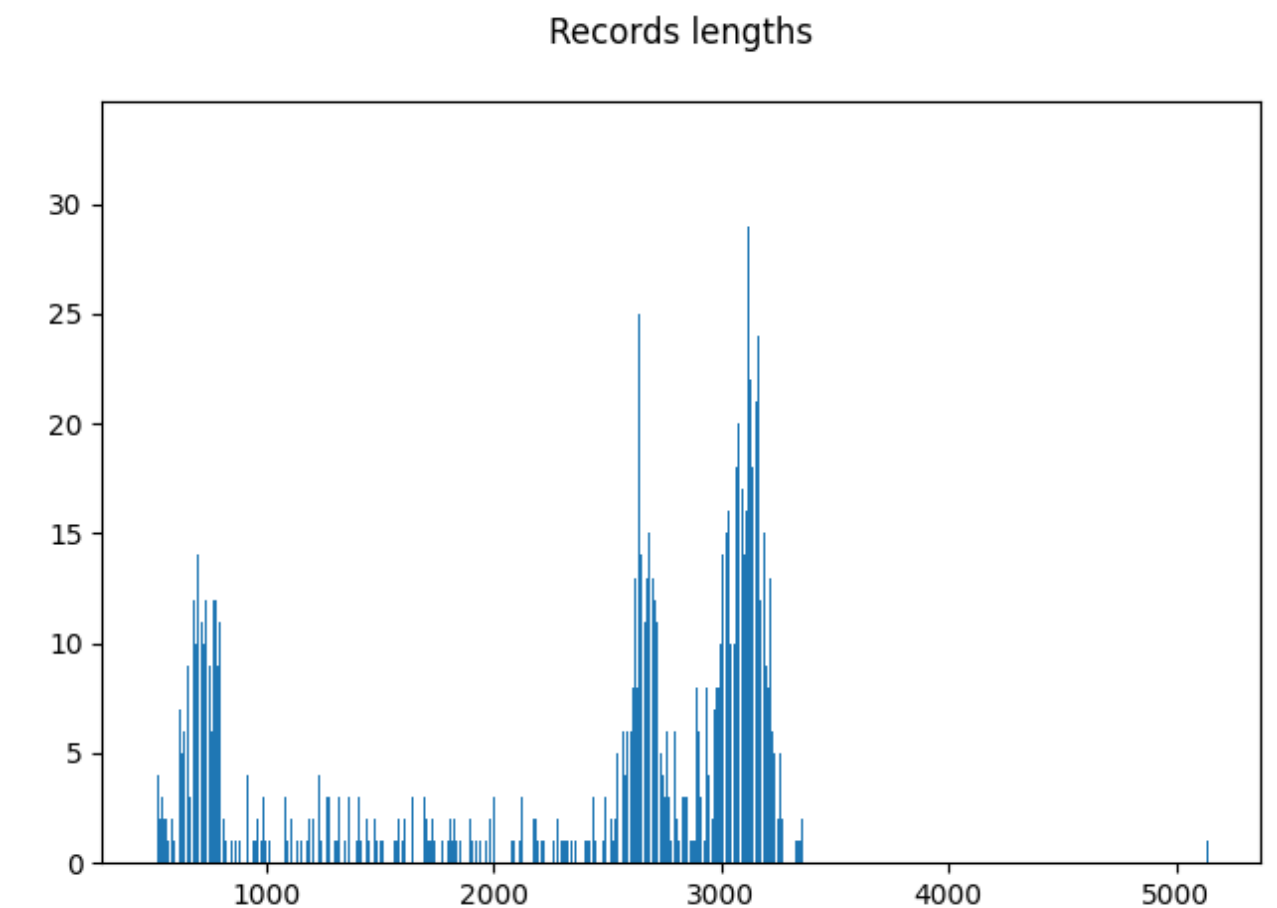
2. Contexte et problématique

Pré-traitement des données :

- Min : 513 points – Max : 5137 points
- Uniformisation des tailles par zero-padding
- Padding : 8192 (aucune perte d'information)

Organisation de la base de données :

- Découpage apprentissage/test 80/20
- Conservation du déséquilibre des classes dans les deux ensembles
- Tous les enregistrements d'un même patient dans un seul des ensembles




3. Travaux réalisés pendant le stage

3. Travaux réalisés pendant le stage

1^{ère} approche : Modèle de réseau de neurones convolutif

Réseau neuronal résiduel (ResNet) → évite le phénomène de disparition du gradient (qui empêche le modèle d'apprendre)



3. Travaux réalisés pendant le stage

Architecture du réseau :

- Nombre de couches
- Nombre de neurones par couches

Hyperparamètres du réseau :

- Algorithme d'optimisation avec un taux d'apprentissage lr
- w_0 et w_1 : poids associés à chaque classe
- Taille des **batches** de données (& nombre d'**epochs**)
=> Sélection par validation croisée 5-Folds

Performances d'un modèle : Si classe 1 = classe positive, F_1 score pour la classe 0 :


$$F_1 = \left(\frac{TN R^{-1} + NPV^{-1}}{2} \right)^{-1}$$

$$TN R = \frac{TN}{TN + FP}$$

$$NPV = \frac{TN}{TN + FN}$$


3. Travaux réalisés pendant le stage

Architecture finale prenant en entrée les deux voies d'un enregistrement



3. Travaux réalisés pendant le stage

Architecture finale ne prenant en entrée que la voie auriculaire d'un enregistrement



3. Travaux réalisés pendant le stage

Résultats sur l'ensemble de données test

- Meilleur modèle prenant en entrée les deux voies d'un enregistrement

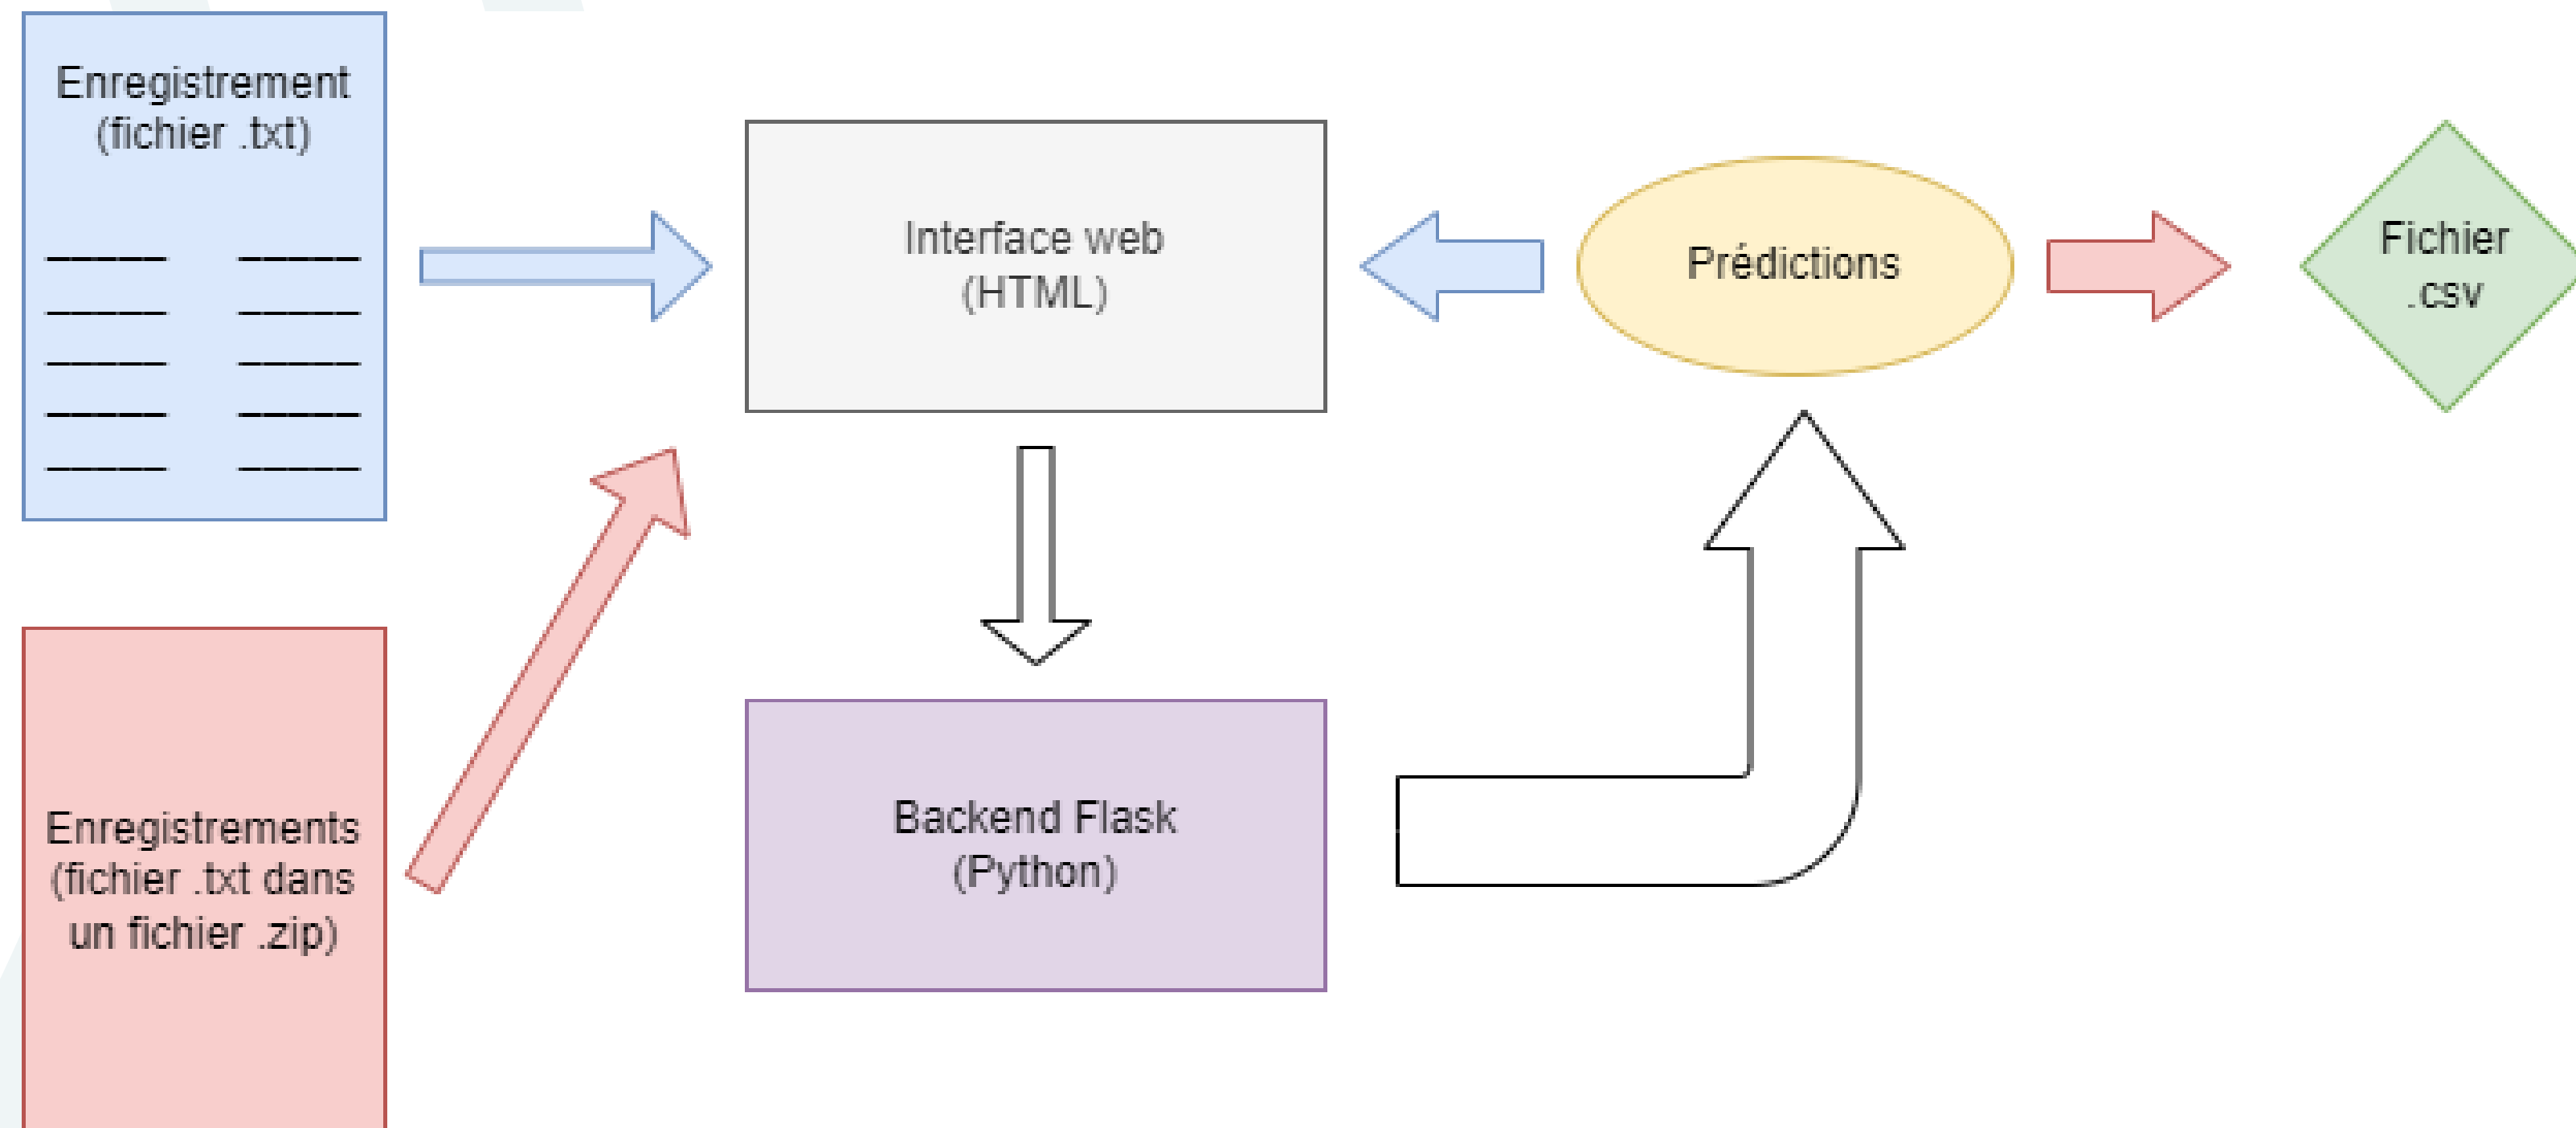
F1 score (pour la classe 0)	Accuracy
92.9 %	96.8 %

- Meilleur modèle prenant en entrée la voie auriculaire d'un enregistrement

F1 score (pour la classe 0)	Accuracy
95.9 %	98.1 %

3. Travaux réalisés pendant le stage

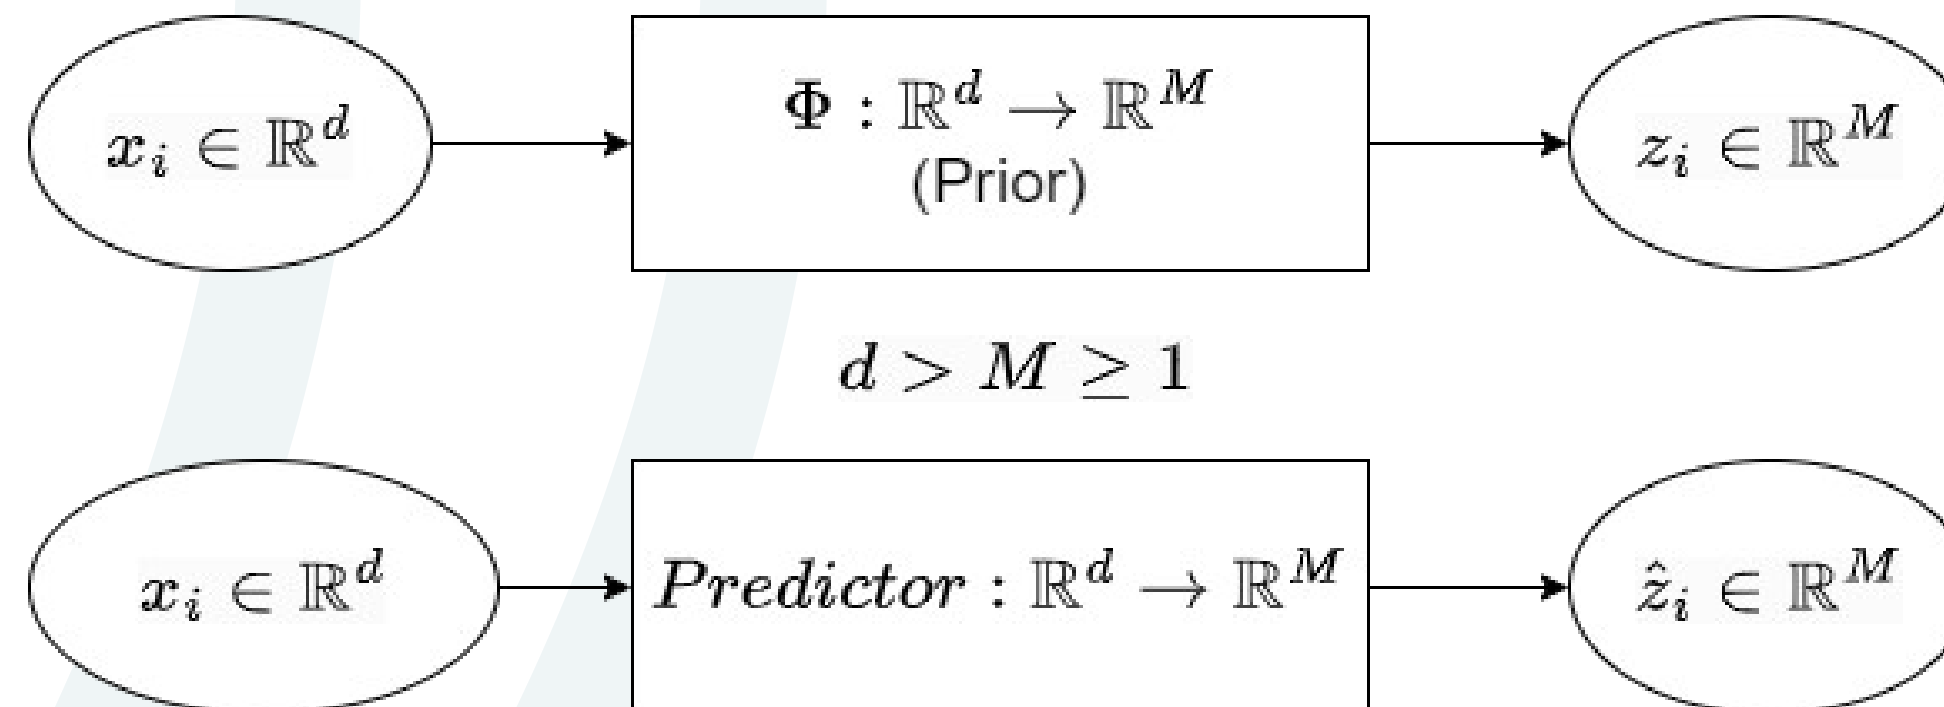
Modèles intégrés à un environnement (application web via Flask)



3. Travaux réalisés pendant le stage

2nde approche : Détection hors distribution par incertitudes de prédiction

- Basé sur l'article « **Conservative Uncertainty Estimation By Fitting Prior Networks** » (*Ciosek et al., 2019*)[\[1\]](#)
- Soient des observations x_i et un ensemble d'observations d'une même distribution X




$$\begin{cases} z_i = \hat{z}_i, \forall x_i \in X \\ z_i \neq \hat{z}_i, \forall x_i \notin X \end{cases}$$

3. Travaux réalisés pendant le stage

- Une fois le Predictor entraîné, on mesure pour toutes les données de la base la distance

$$\|z_i - \hat{z}_i\|^2 \text{ (incertitudes de prédiction).}$$


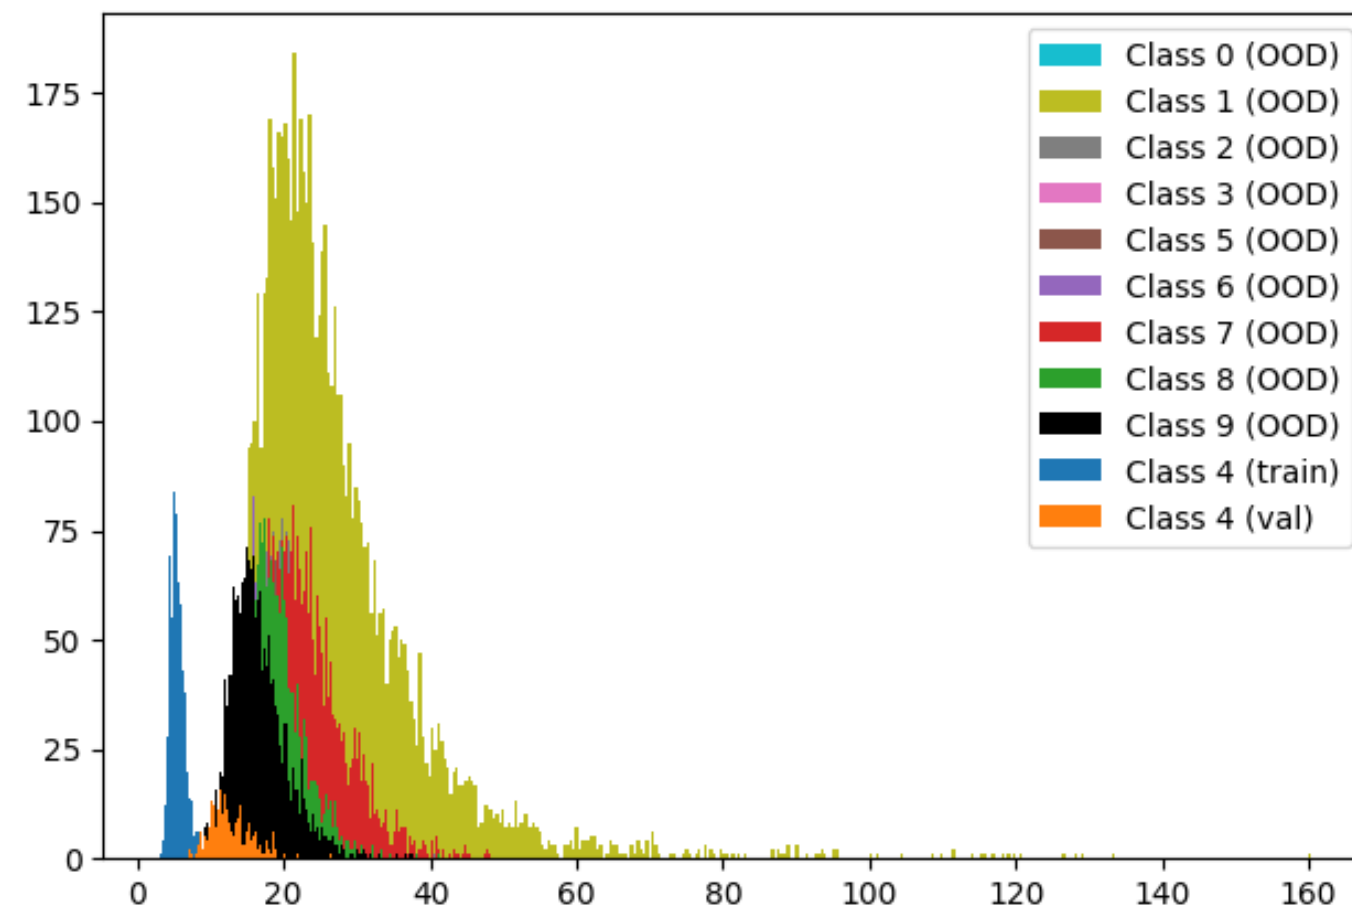


3. Travaux réalisés pendant le stage

Application sur le jeu de données MNIST (chiffres manuscrits de 0 à 9)

- Discriminer les images de 4
- Mêmes architecture pour les Prior et Predictor + même taille de vecteurs en sortie que les auteurs de l'article : $M=512$

Ensemble de données d'apprentissage du jeu MNIST
(4674 données d'apprentissage + 55326 jamais vues)



3. Travaux réalisés pendant le stage

Application sur le jeu de données MNIST (chiffres manuscrits de 0 à 9)

Seuil de décision : valeur qui maximise **TPR - FPR**

96.455% des données bien discriminées sur l'ensemble d'apprentissage du jeu MNIST

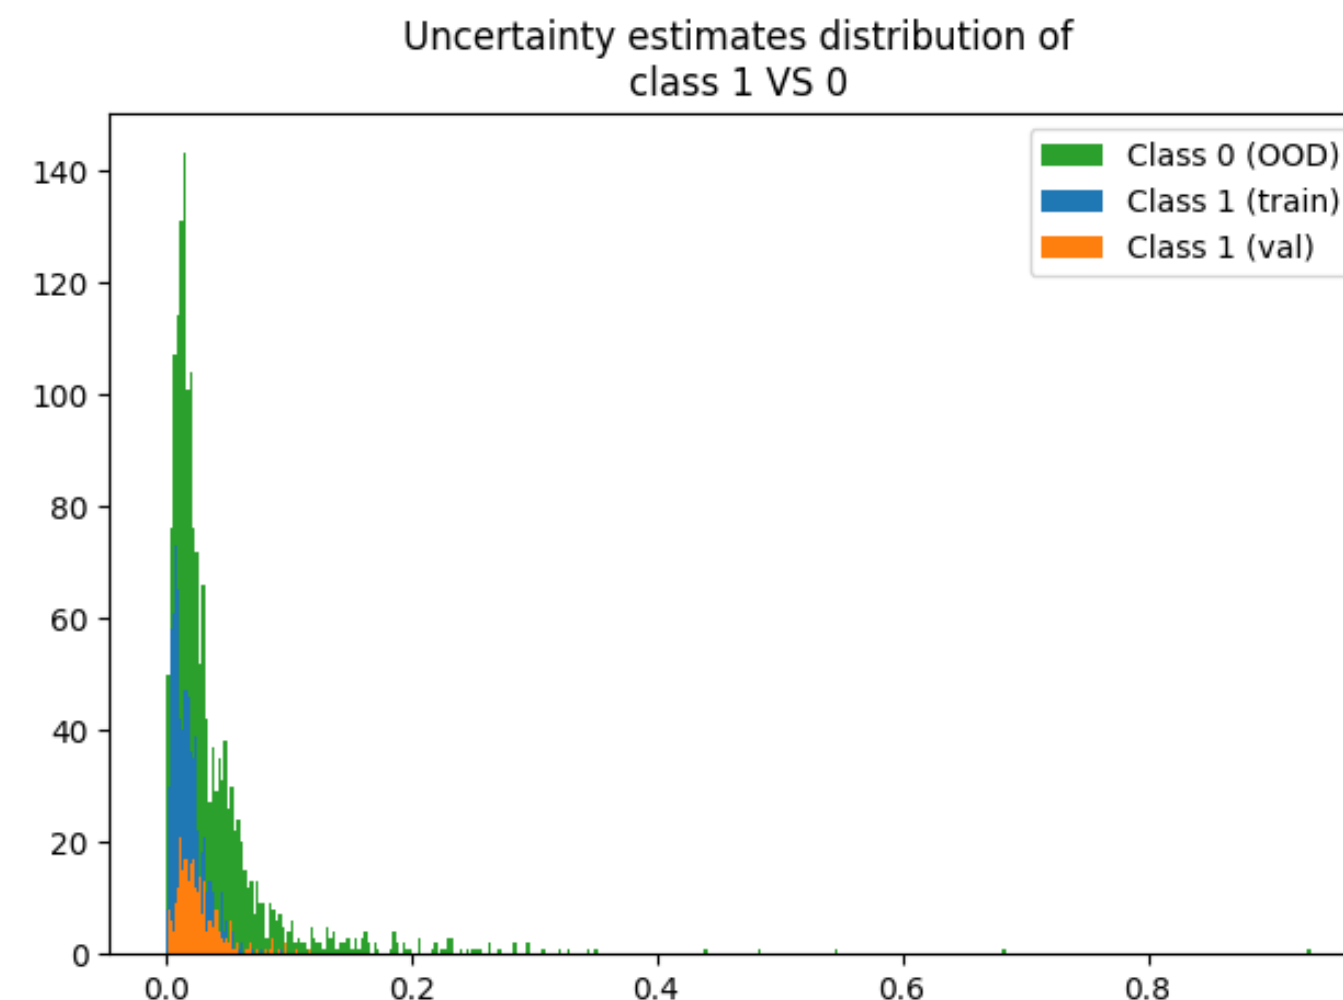
83.520% des données bien discriminées sur l'ensemble test du jeu MNIST

100% des données du jeu CIFAR10 bien discriminées

3. Travaux réalisés pendant le stage

Application sur les données des EGM

- Discrimination des enregistrements présentant une FA
- Modèles Prior et Predictor avec quasiment la même architecture que celle du meilleur modèle à deux voies trouvé précédemment
- Taille de vecteur en sortie : $M=512$




3. Travaux réalisés pendant le stage


Application sur les données des EGM

83.177% des données de l'ensemble d'apprentissage bien discriminées

45.280% des données de l'ensemble test bien discriminées



4. Conclusion



4. Conclusion

- Développement de modèles de réseau de neurones ResNet permettant de discriminer >95% une FA parmi les EGM remontés par les dispositifs des patients
- Modèles intégrés dans une application pouvant automatiquement détecter la présence d'une FA pour de nouveaux EGM remontés
- Détection hors distribution basée sur un article récent : moins efficace que l'approche par réseau neuronal résiduel dans les conditions actuelles d'implémentation
 - optimisation des architectures Prior et Predictor
 - optimisation de l'espace de sortie

Merci de votre attention !

Références

- [1] Ciosek, K., Fortuin, V., Tomioka, R., Hofmann, K., & Turner, R. (2019, September). Conservative uncertainty estimation by fitting prior networks. In *International Conference on Learning Representations*.
- [2] microsoft. (s. d.). GitHub - Microsoft/Conservative-uncertainty-estimation-random-Priors : Source code for Paper Conservative Uncertainty Estimation by Fitting Prior Networks (ICLR 2020). GitHub.
<https://github.com/microsoft/conservative-uncertainty-estimation-random-priors>
- Chollet, F. (2017). Deep learning with python. Manning Publications.